

Probabilitat i simulació amb R

Programari per a l'anàlisi de dades

Robert Buj

18/02/2026

Taula de continguts

Exercicis i casos pràctics amb R	2
Exercici 1	2
Exercici 2	2
Exercici 3	3
Exercici 4	4
Exercici 5	4
Exercici 6	5
Exercici 7	6
Exercici 8	8
Exercici 9	9
Exercici 10	10
Cas pràctic (acumulatiu)	10

Exercicis i casos pràctics amb R

Exercici 1

En un assaig clínic s'ha pres com a mostra un total de 100 pacients. La probabilitat que el pacient pateixi una malaltia cardiovascular és de **0.45**. Calculeu:

- La probabilitat que exactament 30 pacients pateixin aquesta malaltia.
- La probabilitat que almenys 15 pacients tinguin aquesta malaltia. Us sembla curiós aquest resultat?
- Obtingueu la probabilitat que entre 5 i 10 pacients (tots dos inclusivament) tinguin la malaltia.

Resposta:

```
1 # Utilitzarem una distribució binomial
2 # apartat a)
3 n <- 100 # grandària de la mostra
4 p <- 0.45 # probabilitat
5 val1 <- 30
6 dbinom(val1, n, p)
```

```
## [1] 0.0007757151
```

```
1 # apartat b)
2 val2 <- 14
3 pbinom(val2, n, p, lower.tail = FALSE)
```

```
## [1] 1
```

```
1 # apartat c)
2 val3 <- 5
3 val2 <- 9
4 pbinom(val3, n, p) - pbinom(val2, n, p)
```

```
## [1] -3.850508e-15
```

Exercici 2

- Genereu **500** observacions d'una distribució binomial, $B(1, 0.5)$ i emmagatzemeu les dades en un vector anomenat **Bino**. Calculeu les freqüències absolutes i relatives dels valors generats en el vector anterior. Què observeu amb el resultat que heu obtingut?
- Si de **mitjana hi ha 12 individus** per minut travessant un carrer, calculeu la probabilitat que **18 o més** individus travessin aquest carrer en un minut qualsevol.

Resposta:

```
1 # apartat a)
2 set.seed(999) # llavor
3 bino <- rbinom(500, 1, 0.5) # genera 200 observacions amb distribució
4 table(bino) # freqüències absolutes
```

```
## bino
##    0    1
## 253 247
```

```
1 prop.table(table(bino)) # freqüències relatives
```

```
## bino
##     0     1
## 0.506 0.494
```

```

1 # apartat b)
2 lambda <- 12
3 ppois(17, lambda, lower.tail = FALSE) # utilitzem la cua dreta


## [1] 0.0629663

1 1 - ppois(17, lambda) # utilitzem la cua esquerra

## [1] 0.0629663

1 barplot(dpois(x = 0:30, 12), names.arg = 0:30, col = "violet")

```



Exercici 3

Suposem que som en una fàbrica de fàrmacs per al mal de cap que fa un nombre específic de fàrmacs per minut i que segueix una **distribució de Poisson** amb paràmetre $\lambda = 0.5$. Determineu:

- La probabilitat que, en un minut a l'atzar, es generi un únic fàrmac.
- La probabilitat que, en un minut a l'atzar, es generin un màxim de 3 fàrmacs.
- La probabilitat que es generin 4 fàrmacs en 8 minuts.

Resposta:

```

1 # apartat a)
2 dpois(c(1), 0.5)

## [1] 0.3032653

1 # apartat b)
2 ppois(c(2), 0.5) # volem P(X ≤ 3),

## [1] 0.9856123

1 # apartat c)
2 lambda <- 8 / 2
3 dpois(c(8), lambda)

## [1] 0.02977018

```

Exercici 4

Disposen d'una urna amb **40 boles**. **25 són grogues** i les altres són verdes. Assignarem el valor 1 a les boles grogues i el 0 a les boles de color verd:

- Calculeu la probabilitat d'extracció de cada tipus de bola.
- Simulació de l'extracció d'una bola sense reemplaçament.
- Simulació de 9 extraccions amb reemplaçament.

Resposta:

```
1 # apartat a)
2 b_groga <- 25 / 40 # probabilitat boles grogues
3 b_groga

## [1] 0.625

1 b_verda <- 15 / 40 # probabilitat boles verdes
2 b_verda

## [1] 0.375

1 b_groga + b_verda # comprovació

## [1] 1

1 # apartat b)
2 # simulem 1 extracció d'una bola sense reemplaçament
3 sample(c(1, 0), 1, prob = c(0.625, 0.375))

## [1] 1

1 # apartat c)
2 # simulem 9 extraccions amb reemplaçament
3 sample(c(1, 0), 9, rep = T, prob = c(0.625, 0.375))

## [1] 1 0 1 1 0 1 1 1 0
```

Exercici 5

Resoleu els apartats següents:

- Calculeu la probabilitat d'obtenir quatre cares en llançar sis vegades una moneda perfecta.
- Calculeu la probabilitat d'obtenir com a molt quatre cares en llançar sis vegades una moneda perfecta.
- Genereu 10 valors pseudoaleatoris d'una distribució $X \sim B(6, 0.5)$.
- Genereu una mostra de **grandària 10000** d'una distribució normal $N(3, 2)$ i creeu un histograma amb les barres de color amb la mostra que se us ha donat.
- Tal com hem vist en teoria, veurem si la suma d'aquestes dues variables normals $x1 \sim N(6, 0.5)$ i $x2 \sim N(3, 0.6)$ també és una variable normal. **Resposta:**

```
1 # generem la distribució normal i l'emmagatzemem en un vector
2 vect1 <- rnorm(10000, 3, sd = 2)
3 head(vect1) # observem les primeres observacions

## [1] -0.9836115  4.6088225  1.1521722  1.6554406  1.2166075  0.9599479


1 hist(
2   vect1,
3   freq = FALSE, main = "Histograma de la distribució simulada",
4   col = "cadetblue2", border = "blue"
```

```

5 )
6 curve(dnorm(x, mean = 3, sd = 2), from = -5, to = 10, add = TRUE)

```

Histograma de la distribució simulada



Exercici 6

Imaginem un joc en el qual tirem un dau 5 vegades en cada partida i volem simular 8 partides del joc i veure partides guanyadores. Les partides guanyadores seran aquelles que tinguin un 6 en alguna de les tirades del dau.

Resposta:

```

1 set.seed(999) # llavor d'aleatorització
2 sample(1:6, size = 5, replace = TRUE) # generem la partida

## [1] 3 4 5 1 6

1 # utilitzem la funció replicate per simular les 8 partides
2 numRep <- 8
3 repeticions <- replicate(n = numRep, {
4   partida <- sample(1:6, size = 5, replace = TRUE)
5 })
6 repeticions # mirem el resultat de la replicació de les partides.

##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
## [1,]    1    5    2    4    2    3    2    1
## [2,]    2    6    1    1    2    2    2    2
## [3,]    2    6    5    5    4    1    4    5
## [4,]    6    3    3    5    1    1    4    1
## [5,]    3    3    2    1    5    3    4    2

1 class(repeticions) # veiem quin tipus d'objecte és repeticions

```

```
## [1] "matrix" "array"
1 dim(repeticions) # veiem les dimensions de repeticions

## [1] 5 8
1 # amb aquesta instrucció podem veure quines partides són guanyadores
2 repeticions == 6

##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
## [1,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE  TRUE FALSE FALSE FALSE FALSE FALSE FALSE
## [3,] FALSE  TRUE FALSE FALSE FALSE FALSE FALSE FALSE
## [4,]  TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [5,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
```

Exercici 7

Tenim un bol amb 3 tipus de pomes (golden, fuji, gala).

- Quantes permutacions tindrem? La teoria diu que seran 32 permutacions, és a dir, 9 parelles.
- Quantes combinacions podem tenir?

D'altra banda, calculeu quants codons cal que tinguin tots els seus nucleòtids diferents. Recordeu que els nucleòtids són **A**, **T**, **G**, **C**.

Resposta:

```
1 pomes <- c("golden", "fuji", "gala")
2 # apartat a)
3 permutations(3, 2, v = pomes, repeats.allowed = TRUE) # amb repetició

##      [,1] [,2]
## [1,] "fuji" "fuji"
## [2,] "fuji" "gala"
## [3,] "fuji" "golden"
## [4,] "gala" "fuji"
## [5,] "gala" "gala"
## [6,] "gala" "golden"
## [7,] "golden" "fuji"
## [8,] "golden" "gala"
## [9,] "golden" "golden"

1 # apartat b)
2 permutations(n = 3, r = 2, v = pomes) # sense repetició

##      [,1] [,2]
## [1,] "fuji" "gala"
## [2,] "fuji" "golden"
## [3,] "gala" "fuji"
## [4,] "gala" "golden"
## [5,] "golden" "fuji"
## [6,] "golden" "gala"

1 # apartat c)
2 permutations(n = 4, r = 3, v = c("A", "T", "G", "C"), repeats.allowed = TRUE)

##      [,1] [,2] [,3]
## [1,] "A" "A" "A"
```

```

## [2,] "A" "A" "C"
## [3,] "A" "A" "G"
## [4,] "A" "A" "T"
## [5,] "A" "C" "A"
## [6,] "A" "C" "C"
## [7,] "A" "C" "G"
## [8,] "A" "C" "T"
## [9,] "A" "G" "A"
## [10,] "A" "G" "C"
## [11,] "A" "G" "G"
## [12,] "A" "G" "T"
## [13,] "A" "T" "A"
## [14,] "A" "T" "C"
## [15,] "A" "T" "G"
## [16,] "A" "T" "T"
## [17,] "C" "A" "A"
## [18,] "C" "A" "C"
## [19,] "C" "A" "G"
## [20,] "C" "A" "T"
## [21,] "C" "C" "A"
## [22,] "C" "C" "C"
## [23,] "C" "C" "G"
## [24,] "C" "C" "T"
## [25,] "C" "G" "A"
## [26,] "C" "G" "C"
## [27,] "C" "G" "G"
## [28,] "C" "G" "T"
## [29,] "C" "T" "A"
## [30,] "C" "T" "C"
## [31,] "C" "T" "G"
## [32,] "C" "T" "T"
## [33,] "G" "A" "A"
## [34,] "G" "A" "C"
## [35,] "G" "A" "G"
## [36,] "G" "A" "T"
## [37,] "G" "C" "A"
## [38,] "G" "C" "C"
## [39,] "G" "C" "G"
## [40,] "G" "C" "T"
## [41,] "G" "G" "A"
## [42,] "G" "G" "C"
## [43,] "G" "G" "G"
## [44,] "G" "G" "T"
## [45,] "G" "T" "A"
## [46,] "G" "T" "C"
## [47,] "G" "T" "G"
## [48,] "G" "T" "T"
## [49,] "T" "A" "A"
## [50,] "T" "A" "C"
## [51,] "T" "A" "G"
## [52,] "T" "A" "T"
## [53,] "T" "C" "A"
## [54,] "T" "C" "C"
## [55,] "T" "C" "G"

```

```
## [56,] "T" "C" "T"
## [57,] "T" "G" "A"
## [58,] "T" "G" "C"
## [59,] "T" "G" "G"
## [60,] "T" "G" "T"
## [61,] "T" "T" "A"
## [62,] "T" "T" "C"
## [63,] "T" "T" "G"
## [64,] "T" "T" "T"
```

Exercici 8

Donada una distribució $N(20, 9) \sim N(20, 3)$,

- calculeu els quartils (0.25, 0.5, 0.75)
- calculeu la probabilitat $P[X \geq 8]$
- representeu la funció de densitat.

Resposta:

```
1 # apartat a)
2 # per trobar els quartils fem servir qnorm
3 qnorm(c(0.25, 0.5, 0.75), mean = 20, sd = 3, lower.tail = FALSE)
```


```
## [1] 22.02347 20.00000 17.97653
```

```
1 # apartat b)
2 # per calcular la probabilitat utilitzarem pnorm
3 pnorm(c(8), mean = 20, sd = 3, lower.tail = FALSE)
```

```
## [1] 0.9999683
```

```
1 # apartat c)
2 x <- seq(10.128, 29.872, length.out = 1000)
3 plot(
4     x,
5     dnorm(x, mean = 20, sd = 3),
6     xlab = "x",
7     ylab = "Density",
8     main = paste("Normal Distribution: Mean=20, Standard deviation=3 "),
9     col = "violet"
10 )
```

Normal Distribution: Mean=20, Standard deviation=3



Exercici 9

A partir del conjunt de dades `ChickWeight`, busqueu un resum estadístic de la variable `weight`. Busqueu una mostra de **30 pollets** amb l'ordre `sample()` de manera aleatòria anomenada `Lamevamostra3` i genereu un nou conjunt de dades amb tan sols els registres seleccionats a la vostra mostra.

Creeu un dataframe nou, amb aquest subconjunt de dades anomenat `Lamevamostra3`, i comproveu si els **30 registres** segueixen una distribució de la variable `weight` semblant.

Resposta:

```
1 data("ChickWeight")
2 summary(ChickWeight$weight)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      35.0   63.0   103.0   121.8   163.8   373.0

1 n <- 30 # grandària de la mostra
2 set.seed(969) # hi incloem la llavor perquè ens doni el mateix valor sempre
3 lamevamostra3 <- sample(1:nrow(ChickWeight), n, replace = FALSE)
4 lamevamostra3

## [1] 106 572 103 551  57  46 507 285 485 486 363 318 334  29 417 569  10  63 196
## [20] 533 320 194 505  17  11 133 421 300 336 180

1 datamostra <-
2   ChickWeight[c(
3     324, 61, 186, 10, 291, 279, 207, 391, 403, 491, 82, 421, 460, 393, 181,
4     375, 549, 441, 378, 249, 223, 16, 541, 363, 258, 9, 353, 411, 344
5   ), 1] # triem la primera columna, és a dir la variable weight, dels registres de la nostra mostra
6 summary(datamostra) # generem el summary del valor dels nostres registres

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
```

```
##      41.0      64.0     135.0     137.1     184.0     321.0
```

Exercici 10

Resoleu els exercicis següents i comenteu els resultats obtinguts: a) S'ha fet un estudi a partir del qual se sap que un determinat fàrmac redueix els efectes de l'al·lèrgia al pol·len. Amb les dades obtingudes fins al moment, només en el 4 % dels casos no ha fet efecte.

- Quin tipus de distribució representa aquest cas? Quina és la probabilitat que si es realitza la tècnica 100 vegades hi hagi més de 5 casos en els quals el fàrmac no sigui efectiu?
- La durada mitjana de recuperació d'una grip comuna és de 7 ± 2 dies (**mitjana i desviació estàndard**). Suposant que es tracta d'una distribució normal, calculeu la probabilitat que la recuperació duri entre 6 i 10 dies.

Resposta:

```
1 # apartat a)
2 # Es tracta d'una distribució binomial, ja que comptem el nombre d'èxits
3 # (presentar rebuig) en una seqüència d'assajos (nombre de vegades que s'aplica
4 # la tècnica) de Bernoulli (2 possibles estats: sense/amb rebuig) independents
5 # entre si.
6 1 - pbinom(c(5), 100, 0.04)
```

```
## [1] 0.2116251
```

```
1 # apartat b)
2 # restem les 2 distribucions normals
3 pnorm(10, 7, 2) - pnorm(6, 7, 2)
```

```
## [1] 0.6246553
```

Cas pràctic (acumulatiu)

En aquest exercici, estudiarem la distribució d'unes dades unidimensionals. Les dades que farem servir són el dataset **Faithful** incorporat a la biblioteca **Stepfun** de R. Aquest dataset ens dona informació sobre el temps d'espera entre erupcions i la durada de l'erupció del guèiser Old Faithful al Parc Nacional de Yellowstone, Wyoming, Estats Units (<https://stat.ethz.ch/R-manual/Rdevel/library/datasets/html/faithful.html>).

- Feu un estudi estadístic descriptiu de la variable **eruptions** i genereu el gràfic de tija i fulles.
- Genereu un gràfic de tija i fulles amb aquestes dades.
- Genereu un histograma. Definiu intervals menors a l'histograma i afegiu al gràfic la funció de densitat superposada.
- Utilitzant la funció **ecdf** de la biblioteca estàndard **Stepfun**, representeu la funció de distribució empírica de la mostra, és a dir, una distribució a partir d'aquestes dades que proporcioni una certa semblança a una distribució veritable associada amb la població.
- Creieu que la distribució de l'apartat anterior correspon a alguna distribució estàndard coneguda?
- Selecioneu les erupcions que duren més de 3 minuts. Què podeu dir d'aquestes dades?
- Genereu un gràfic amb les dades de l'apartat f). Creieu que s'assemblen a alguna distribució?

Resposta:

```
1 # apartat a)
2 data("faithful")
3 attach(faithful)
4 summary(eruptions)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.600   2.163   4.000   3.488   4.454   5.100
```

```

1 fivenum(eruptions)

## [1] 1.6000 2.1585 4.0000 4.4585 5.1000


1 # apartat b)
2 stem(eruptions, scale = 1, width = 80) # gràfic de tija i fulles

##
## The decimal point is 1 digit(s) to the left of the |
##
## 16 | 070355555588
## 18 | 000022233333355777777777888822335777888
## 20 | 00002223378800035778
## 22 | 0002335578023578
## 24 | 00228
## 26 | 23
## 28 | 080
## 30 | 7
## 32 | 2337
## 34 | 250077
## 36 | 0000823577
## 38 | 2333335582225577
## 40 | 0000003357788888002233555577778
## 42 | 03335555778800233333555577778
## 44 | 0222233555778000000002333357778888
## 46 | 00002333577000000023578
## 48 | 00000022335800333
## 50 | 0370

1 # apartat c)
2 hist(eruptions, seq(1.6, 5.2, 0.2), prob = TRUE, col = "blue")
3 lines(density(eruptions, bw = 0.1))
4 rug(eruptions)


```

Histogram of eruptions



```
1 # apartat d)  
2 plot(ecdf(eruptions), do.points = FALSE, verticals = TRUE)
```

ecdf(eruptions)



```
1 # apartat e)  
2 # No s'assembla a una distribuci3 standard coneguda. Podem dir que 3s una
```

```

3  # distribució acumulada i potser una distribució bimodal.
4  # apartat f)
5  # Seleccióem les dades amb la condició requerida
6  long <- eruptions[eruptions > 3]
7  # apartat g)
8  plot(ecdf(long), do.points = FALSE, verticals = TRUE)
9  x <- seq(3, 5.4, 0.01)
10 lines(x, pnorm(x, mean = mean(long), sd = sqrt(var(long))), lty = 3)

```

