

Introducció al machine learning amb R

Programari per a l'anàlisi de dades

Robert Buj

18/02/2026

Taula de continguts

Exercicis i casos pràctics amb R	2
Exercici 1. Models supervisats. Anàlisi de regressió múltiple	2
Exercici 2. Models supervisats. Model de classificació SVM	3
Exercici 3. Models no supervisats. PCA	3
Exercici 4. Agrupament jeràrquic. Agrupament jeràrquic aglomeratiu	5
Exercici 5. Agrupament jeràrquic. Agrupament jeràrquic divisiu	6
Exercici 6. Agrupament jeràrquic. Agrupament jeràrquic aglomeratiu	8
Exercici 7. Agrupament jeràrquic. Agrupament jeràrquic divisiu	10
Exercici 8. Agrupament no jeràrquic	12
Exercici 9. Agrupament no jeràrquic	15
Exercici 10. ANOVA	19
Cas pràctic 1. Models supervisats. Regressió lineal i múltiple	19
Cas pràctic 2. Models d'aprenentatge automàtic i ANOVA	24
Cas pràctic 3. ANOVA	35

Exercicis i casos pràctics amb R

Exercici 1. Models supervisats. Anàlisi de regressió múltiple

A partir del conjunt de dades swiss del paquet `datasets`, calculeu la matriu de correlació i, a partir d'aquesta, feu una anàlisi de regressió múltiple. Raoneu els resultats.

Resposta:

Carreguem el conjunt de dades:

```
1 data(swiss)
```

Fem la matriu de correlació:

```
1 cor_matrix <- cor(swiss, method = "pearson")
```

Podem observar que no hi ha una alta correlació, a priori, entre cap de les variables.

Procedim a fer l'anàlisi de regressió múltiple:

```
1 # Fem una anàlisi de regressió múltiple
2 model <- lm(
3   Fertility ~ Agriculture + Examination + Education + Catholic + Infant.Mortality,
4   data = swiss
5 )
6 # Mostrem un resum del model
7 summary(model)
```

```
##
## Call:
## lm(formula = Fertility ~ Agriculture + Examination + Education +
##     Catholic + Infant.Mortality, data = swiss)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.2743  -5.2617   0.5032   4.1198  15.3213
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    66.91518   10.70604   6.250 1.91e-07 ***
## Agriculture    -0.17211    0.07030  -2.448  0.01873 *
## Examination    -0.25801    0.25388  -1.016  0.31546
## Education      -0.87094    0.18303  -4.758 2.43e-05 ***
## Catholic        0.10412    0.03526   2.953  0.00519 **
## Infant.Mortality 1.07705    0.38172   2.822  0.00734 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.165 on 41 degrees of freedom
## Multiple R-squared:  0.7067, Adjusted R-squared:  0.671
## F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

El resultat anterior indica que el model té ajust moderat i el valor d'R-Squared, que no és gaire pròxim a l'1, indica que existeixen variables irrelevantes en el model. D'altra banda, el p-value tan baix pot indicar que el model en general és significatiu però millorable.

Exercici 2. Models supervisats. Model de classificació SVM

A partir del conjunt de dades `Pima.tr` del paquet `MASS` que fa referència a dades de diabetis de pacients índies, feu un model de classificació SVM i feu una classificació de pacients per predir si estan en risc de patir diabetis. Per fer aquest exercici utilitzeu el paquet `kernlab` per entrenar el model SVM.

Resposta:

```
1 # Carreguem el paquet MASS
2 library(MASS)
3 # Carreguem el conjunt de dades de 'Diabetesin Pima Indian Women'
4 data(Pima.tr)
5 # Mostrem el dataset
6 head(Pima.tr)

##      npreg glu bp skin  bmi   ped age type
## 1      5  86 68  28 30.2 0.364  24   No
## 2      7 195 70  33 25.1 0.163  55  Yes
## 3      5  77 82  41 35.8 0.156  35   No
## 4      0 165 76  43 47.9 0.259  26   No
## 5      0 107 60  25 26.4 0.133  23   No
## 6      5  97 76  27 35.6 0.378  52  Yes

1 # Dividim el conjunt de dades en entrenament i prova
2 set.seed(123)
3 indices_entrenament <- sample(1:nrow(Pima.tr), 0.5 * nrow(Pima.tr)) # poden fer-se proves triant un alt
4 conjunt_entrenament <- Pima.tr[indices_entrenament, ]
5 conjunt_prova <- Pima.tr[-indices_entrenament, ]
6 # Carreguem el paquet "kernlab" per a SVM
7 library(kernlab)
8 # Entrenem un model SVM
9 model_svm <- ksvm(type ~ ., data = conjunt_entrenament)
10 # Fem prediccions en el conjunt de prova
11 prediccions <- predict(model_svm, newdata = conjunt_prova)
12 # Calculem la matriu de confusió
13 matriu_confusio <- table(Real = conjunt_prova$type, Prediccio = prediccions)
14 # Calcular la precisió
15 precisió <- sum(diag(matriu_confusio)) / sum(matriu_confusio)
16 cat("Precisió del model SVM:", precisió, "\n")

## Precisió del model SVM: 0.73

1 # Mostrem la matriu de confusió
2 matriu_confusio

##      Prediccio
## Real  No  Yes
##   No  57   5
##   Yes 22  16
```

Els ajustos de predicció del model són del 65 %.

Exercici 3. Models no supervisats. PCA

A partir del conjunt de dades `Iris`, es demana fer una anàlisi de components centrat, per exemple, en les mesures de longitud i amplada del sèpal i el pètal.

Resposta:

```

1 # Carreguem el conjunt de dades Iris
2 data(iris)
3 ## ## 1 ## 2 ## 3 ## 4 ## 5 ## 6 5.4 3.9 1.7 0.4 setosa
4 # Visualitzem les primeres files del conjunt de dades
5 head(iris)


## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1 5.1 3.5 1.4 0.2 setosa
## 2 4.9 3.0 1.4 0.2 setosa
## 3 4.7 3.2 1.3 0.2 setosa
## 4 4.6 3.1 1.5 0.2 setosa
## 5 5.0 3.6 1.4 0.2 setosa
## 6 5.4 3.9 1.7 0.4 setosa

1 # Seleccionem les variables rellevants per a l'anàlisi de PCA (per exemple,
2 # les mesures de longitud i ample del sèpal i pètal)
3 selection_iris <- iris[, c("Sepal.Length", "Sepal.Width", "Petal.Length", "Petal.Width")]
4 # Estandarditzem les dades (és recomanable per a PCA)
5 scaled_data <- scale(selection_iris)
6 # Fem el PCA
7 pca_result_iris <- princomp(scaled_data)
8 # Resum dels resultats
9 summary(pca_result_iris)

## Importance of components:
##              Comp.1      Comp.2      Comp.3      Comp.4
## Standard deviation  1.7026571 0.9528572 0.38180950 0.143445939
## Proportion of Variance 0.7296245 0.2285076 0.03668922 0.005178709
## Cumulative Proportion 0.7296245 0.9581321 0.99482129 1.000000000

1 # Realitzem una representació gràfica de la pca_result_iris
2 plot(pca_result_iris)

```



El primer component 1 (Comp. 1) té una desviació estàndard d'aproximadament 1.7027, que representa la major variabilitat de totes les components definides i, a més, representa el 72.96 %, aproximadament, de la variància total en les dades. Per tant, la Comp. 1 és el component més important per explicar la variació de les dades.


Exercici 4. Agrupament jeràrquic. Agrupament jeràrquic aglomeratiu

Feu un agrupament jeràrquic aglomeratiu amb el paquet de dades `birthwt` del paquet `MASS`.

Resposta:

```
1 # Agrupament jeràrquic aglomeratiu. Cada observació és un clúster que es va
2 # organitzant fins a convergir en una única branca central.
3 library(MASS)
4 library(cluster)
5 data("birthwt")
6 data_birth <- birthwt
7 d_agl <- dist(data_birth, method = "euclidean") # especifiquem els valors de distància
8 hc_agl <- hclust(d_agl, method = "complete") # calculem el clúster jeràrquic
9 plot(hc_agl, cex = 0.6, hang = -1, main = "Dendrograma de clúster") # representem el dendrograma
```

Dendrograma de clúster




d_agl
hclust (*, "complete")

Si utilitzem la funció `agnes` obtindrem, a més del dendrograma, el coeficient d'aglomeració que indica el grau de fortalesa de l'agrupament, millor com més pròxim a 1.

```
1 # Agrupament jeràrquic aglomeratiu
2 hc_ag <- agnes(data_birth, method = "complete") # calculem els clústers jeràrquics
3 pltree(hc_ag, cex = 0.6, hang = -1, main = "Dendrograma d'agnes") # representem dendrograma
```

Dendrograma d'agnes



data_birth
agnes (*, "complete")

```
1 hc_ag$ac # calculem el coeficient d'aglomeració
```

```
## [1] 0.9917573
```

Podem observar que el coeficient d'aglomeració és molt pròxim a 1, fet que indica que l'agrupació és forta.

Exercici 5. Agrupament jeràrquic. Agrupament jeràrquic divisiu

Feu un agrupament jeràrquic divisiu amb el paquet de dades `birthwt` del paquet `MASS`.

Resposta:


Vegem ara un exemple d'agrupament divisional jeràrquic utilitzant la funció `diana`. Carreguem inicialment les dades corresponents al conjunt de dades.

```
1 library(MASS)
2 library(cluster)
3 data_birth <- birthwt
```

Ara farem l'agrupament jeràrquic:

```
1 # Agrupament divisional jeràrquic
2 hc_div <- diana(data_birth) # calculem els clústers jeràrquics
3 pltree(hc_div, cex = 0.6, hang = -1, main = "Dendrograma de Diana") # representem el dendrograma
```

Dendrograma de Diana



data_birth
diana (*, "NA")


```
1 hc_div$dc # calculem el coeficient de divisió
```

```
## [1] 0.9907511
```

Igualment, el coeficient de divisió és un bon valor indicatiu de l'agrupació. Una vegada creats els agrupaments, associem els clústers a les observacions de dades. Una opció senzilla seria afegir a l'anterior representació gràfica la divisió per clúster de la manera següent:

```
1 pltree(hc_div, hang = -1, cex = 0.6)  
2 rect.hclust(hc_div, k = 10, border = 2:10)
```

Dendrogram of diana(x = data_birth)



Exercici 6. Agrupament jeràrquic. Agrupament jeràrquic aglomeratiu

Feu un agrupament jeràrquic de tipus aglomeratiu per al conjunt de dades `melanoma` del paquet `MASS`.

Resposta:


Carreguem el dataset `melanoma` i fem l'agrupament jeràrquic aglomeratiu:

```

1 # Agrupament jeràrquic aglomeratiu. Cada observació és un clúster que es va
2 # organitzant fins a convergir en una única branca central.
3 library(MASS)
4 library(cluster)
5 data_mel <- Melanoma
6 d_agl_m <- dist(data_mel, method = "euclidean") ## especifiquem els valors de distància
7 hc_agl_m <- hclust(d_agl_m, method = "complete") ## calculem el clúster jeràrquic
8 plot(hc_agl_m, cex = 0.6, hang = -1, main = "Dendrograma de cluster") ## representem el dendrograma

```


Dendrograma de cluster



d_agl_m
hclust (*, "complete")

Repetim el mateix procés amb la funció `agnes()`:

```
1 hc_ag_m <- agnes(data_mel, method = "complete") # calculem els clústers jeràrquics
2 pltree(hc_ag_m, cex = 0.6, hang = -1, main = "Dendrograma d'agnes") # representem dendrograma
```

Dendrograma d'agnes



data_mel
agnes (*, "complete")

Ara calculem el coeficient d'aglomeració:

```
1 hc_ag_m$ac # calculem el coeficient d'aglomeració
```

```
## [1] 0.9941753
```

Podem observar que el coeficient d'aglomeració és molt pròxim a 1, fet que indica que l'agrupació és forta.

Exercici 7. Agrupament jeràrquic. Agrupament jeràrquic divisiu

Feu un agrupament jeràrquic de tipus divisiu per al conjunt de dades melanoma del paquet MASS.

Resposta:

Carreguem el dataset corresponent:

```
1 library(MASS)
2 library(cluster)
3 data("Melanoma")
4 data_mel <- Melanoma
5 head(data_mel)
```

```
##   time status sex age year thickness ulcer
## 1   10      3   1  76 1972      6.76     1
## 2   30      3   1  56 1968      0.65     0
## 3   35      2   1  41 1977      1.34     0
## 4   99      3   0  71 1968      2.90     0
## 5  185      1   1  52 1965     12.08     1
## 6  204      1   1  28 1971      4.84     1
```


Realitzem ara un exemple d'agrupament divisional jeràrquic utilitzant la funció `diana()`:

```

1 # Agrupament divisional jeràrquic
2 hc_div_m <- diana(data_mel) # calculem els clústers jeràrquics
3 pltree(hc_div_m, cex = 0.6, hang = -1, main = "Dendrograma de Diana") ## representem el dendrograma

```

Dendrograma de Diana



data_mel
diana (*, "NA")

Calculem el coeficient de divisió:

```

1 hc_div_m$dc # calculem el coeficient de divisió

```

```
## [1] 0.9940069
```


Una vegada creats els agrupaments, associem els clústers a les observacions de dades. Una opció senzilla seria afegir a l'anterior representació gràfica la divisió per clúster de la manera següent:

```

1 pltree(hc_div_m, hang = -1, cex = 0.6)
2 rect.hclust(hc_div_m, k = 10, border = 2:10)

```

Dendrogram of diana(x = data_mel)



Exercici 8. Agrupament no jeràrquic

Feu un agrupament no jeràrquic utilitzant el conjunt de dades `birthwt` del paquet `MASS`.

Resposta:

Carreguem el conjunt de dades:

```
1 # invoquem el conjunt de dades birthwt
2 data_birth_k <- MASS::birthwt
3 head(data_birth_k)
```


```
##      low age lwt race smoke ptl ht ui ftv  bwt
## 85    0  19 182   2    0  0  0  1  0 2523
## 86    0  33 155   3    0  0  0  0  3 2551
## 87    0  20 105   1    1  0  0  0  1 2557
## 88    0  21 108   1    1  0  0  1  2 2594
## 89    0  18 107   1    1  0  0  1  0 2600
## 91    0  21 124   3    0  0  0  0  0 2622
```

```
1 # comprovem el tipus de variables. Hi ha 10 variables, totes elles numèriques,
2 # encara que race es podria considerar categòrica
3 str(data_birth_k)
```

```
## 'data.frame':   189 obs. of  10 variables:
## $ low  : int  0 0 0 0 0 0 0 0 0 0 ...
## $ age  : int  19 33 20 21 18 21 22 17 29 26 ...
## $ lwt  : int  182 155 105 108 107 124 118 103 123 113 ...
## $ race : int  2 3 1 1 1 3 1 3 1 1 ...
## $ smoke: int  0 0 1 1 1 0 0 0 1 1 ...
## $ ptl  : int  0 0 0 0 0 0 0 0 0 0 ...
```

```
## $ ht : int 0 0 0 0 0 0 0 0 0 0 ...
## $ ui : int 1 0 0 1 1 0 0 0 0 0 ...
## $ ftv : int 0 3 1 2 0 0 1 1 1 0 ...
## $ bwt : int 2523 2551 2557 2594 2600 2622 2637 2637 2663 2665 ...
```

```
1 # considerem race la nostra variable objectiu
2 # fem un gràfic de dispersió segons la variable predictora
3 pairs(data_birthe_k[-11], col = data_birthe_k$race)
```



```
1 # comprovem el grau de correlació entre la resta de variables numèriques
2 corr <- cor(data_birthe_k[-11])
3 corr
```

```
##          low      age      lwt      race      smoke      ptl
## low      1.00000000 -0.11893928 -0.16962694  0.137792751  0.16140431  0.196087267
## age     -0.11893928  1.00000000  0.18007315 -0.172817953 -0.04434618  0.071606386
## lwt     -0.16962694  0.18007315  1.00000000 -0.165048544 -0.04417908 -0.140029003
## race     0.13779275 -0.17281795 -0.16504854  1.000000000 -0.33903074  0.007951293
## smoke    0.16140431 -0.04434618 -0.04417908 -0.339030745  1.00000000  0.187557063
## ptl      0.19608727  0.07160639 -0.14002900  0.007951293  0.18755706  1.000000000
## ht       0.15237025 -0.01583700  0.23636040  0.019929917  0.01340704 -0.015399579
## ui       0.16904283 -0.07515558 -0.15276317  0.053602088  0.06215900  0.227585340
## ftv     -0.06296026  0.21539394  0.14052746 -0.098336254 -0.02801314 -0.044429660
## bwt     -0.78480516  0.09031781  0.18573328 -0.194713487 -0.19044806 -0.154653390
##          ht      ui      ftv      bwt
## low      0.15237025  0.16904283 -0.06296026 -0.78480516
## age     -0.01583700 -0.07515558  0.21539394  0.09031781
## lwt      0.23636040 -0.15276317  0.14052746  0.18573328
## race     0.01992992  0.05360209 -0.09833625 -0.19471349
## smoke    0.01340704  0.06215900 -0.02801314 -0.19044806
## ptl     -0.01539958  0.22758534 -0.04442966 -0.15465339
## ht       1.00000000 -0.10858506 -0.07237255 -0.14598189
```

```
## ui      -0.10858506  1.00000000 -0.05952341 -0.28392741
## ftv     -0.07237255 -0.05952341  1.00000000  0.05831777
## bwt     -0.14598189 -0.28392741  0.05831777  1.00000000
```

A partir d'aquests gràfics podem intuir quines variables poden aportar més informació per a la formació de grups. No sembla que hi hagi cap combinació clara. Farem la combinació amb la variable `bwt`. Seria adequat transformar la variable `race` de tipus sencer en una altra variable de tipus categòric.

```
1 # Construïm els grups de clústers, crearem 3 grups que són els tipus de raça (*race*)
2 grups_km <- kmeans(data_birth_k, 3) # 10 variables, 3 tipus de raça
3 grups_km
```


```
## K-means clustering with 3 clusters of sizes 73, 54, 62
##
## Cluster means:
##      low      age      lwt      race      smoke      ptl      ht
## 1 0.0000000 23.24658 128.9041 1.917808 0.4109589 0.1506849 0.02739726
## 2 0.0000000 24.20370 138.4630 1.537037 0.2407407 0.1111111 0.05555556
## 3 0.9516129 22.38710 123.3548 2.032258 0.5000000 0.3225806 0.11290323
##      ui      ftv      bwt
## 1 0.15068493 0.8904110 3009.986
## 2 0.03703704 0.7407407 3804.148
## 3 0.24193548 0.7258065 2118.935
##
## Clustering vector:
##  85  86  87  88  89  91  92  93  94  95  96  97  98  99 100 101 102 103 104 105
##   3   3   3   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1
## 106 107 108 109 111 112 113 114 115 116 117 118 119 120 121 123 124 125 126 127
##   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1
## 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147
##   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1
## 148 149 150 151 154 155 156 159 160 161 162 163 164 166 167 168 169 170 172 173
##   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   2   2   2
## 174 175 176 177 179 180 181 182 183 184 185 186 187 188 189 190 191 192 193 195
##   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2
## 196 197 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215 216
##   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2   2
## 217 218 219 220 221 222 223 224 225 226   4  10  11  13  15  16  17  18  19  20
##   2   2   2   2   2   2   2   2   2   2   3   3   3   3   3   3   3   3   3
##  22  23  24  25  26  27  28  29  30  31  32  33  34  35  36  37  40  42  43  44
##   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3
##  45  46  47  49  50  51  52  54  56  57  59  60  61  62  63  65  67  68  69  71
##   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3
##  75  76  77  78  79  81  82  83  84
##   3   3   3   3   3   3   3   3   3
##
## Within cluster sum of squares by cluster:
## [1] 3577022 4604811 9487300
## (between_SS / total_SS =  82.4 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"
```

```

1 grups_km$cluster # grup al qual pertanyen les dades

## 85 86 87 88 89 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105
## 3 3 3 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
## 106 107 108 109 111 112 113 114 115 116 117 118 119 120 121 123 124 125 126 127
## 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
## 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147
## 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
## 148 149 150 151 154 155 156 159 160 161 162 163 164 166 167 168 169 170 172 173
## 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 2 2 2
## 174 175 176 177 179 180 181 182 183 184 185 186 187 188 189 190 191 192 193 195
## 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
## 196 197 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215 216
## 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
## 217 218 219 220 221 222 223 224 225 226 4 10 11 13 15 16 17 18 19 20
## 2 2 2 2 2 2 2 2 2 2 3 3 3 3 3 3 3 3 3 3
## 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 40 42 43 44
## 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3
## 45 46 47 49 50 51 52 54 56 57 59 60 61 62 63 65 67 68 69 71
## 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3
## 75 76 77 78 79 81 82 83 84
## 3 3 3 3 3 3 3 3 3
1 plot(grups_km$cluster)

```



Exercici 9. Agrupament no jeràrquic

Feu un agrupament no jeràrquic utilitzant la tècnica `k-means()` per al conjunt de dades `melanoma` del paquet `MASS`. Valoreu els resultats per a diferents nombres de clústers i definint una determinada variable objectiu. Podeu transformar alguna variable sencera de manera categòrica, per exemple, la referent a l'estatus.

Resposta:

Carreguem el conjunt de dades:

```

1 # invoquem el conjunt de dades melanoma
2 data("Melanoma")
3 head(Melanoma)

```

```

##   time status sex age year thickness ulcer
## 1   10      3   1  76 1972      6.76     1
## 2   30      3   1  56 1968      0.65     0
## 3   35      2   1  41 1977      1.34     0
## 4   99      3   0  71 1968      2.90     0
## 5  185      1   1  52 1965     12.08     1
## 6  204      1   1  28 1971      4.84     1

```

```

1 # comprovem el tipus de variables. Hi ha 10 variables, totes elles numèriques,
2 # encara que status es podria considerar categòrica
3 str(Melanoma)

```

```


## 'data.frame':   205 obs. of  7 variables:
##  $ time      : int  10 30 35 99 185 204 210 232 232 279 ...
##  $ status    : int   3 3 2 3 1 1 1 3 1 1 ...
##  $ sex       : int   1 1 1 0 1 1 1 0 1 0 ...
##  $ age       : int  76 56 41 71 52 28 77 60 49 68 ...
##  $ year      : int  1972 1968 1977 1968 1965 1971 1972 1974 1968 1971 ...
##  $ thickness: num   6.76 0.65 1.34 2.9 12.08 ...
##  $ ulcer     : int   1 0 0 0 1 1 1 1 1 1 ...

```

```

1 # considerem race la nostra variable objectiu
2 # fem un gràfic de dispersió segons la variable predictora
3 pairs(Melanoma[-7], col = Melanoma$status)

```



```

1 # comprovem el grau de correlació entre la resta de variables numèriques
2 corr_m <- cor(Melanoma[-7])
3 corr_m

```



```
##           time      status      sex      age      year
## time      1.0000000  0.31614601 -0.146499215 -0.30151794 -0.485504359
## status    0.3161460  1.00000000 -0.098967345  0.01596386  0.138166927
## sex       -0.1464992 -0.09896735  1.000000000  0.06833741 -0.002645159
## age       -0.3015179  0.01596386  0.068337413  1.000000000  0.188229089
## year      -0.4855044  0.13816693 -0.002645159  0.18822909  1.000000000
## thickness -0.2354087 -0.20472162  0.185412563  0.21247979 -0.133345424
##           thickness
## time      -0.2354087
## status    -0.2047216
## sex        0.1854126
## age        0.2124798
## year      -0.1333454
## thickness  1.0000000
```

A partir d'aquests gràfics podem intuir quines variables poden aportar més informació per a la formació de grups.

```
1 # Construïm els grups de clústers, crearem 3 grups que són els tipus estatus
2 grups_km <- kmeans(Melanoma[-7], 3) ## 10 variables, 3 tipus d'estatus
3 grups_km


## K-means clustering with 3 clusters of sizes 55, 107, 43
##
## Cluster means:
##           time      status      sex      age      year thickness
## 1 3644.4182 2.018182 0.3454545 44.36364 1967.345 2.446000
## 2 1984.4953 1.850467 0.3457944 54.62617 1971.421 2.224019
## 3  663.7209 1.348837 0.5348837 57.44186 1969.419 5.257442
##
## Clustering vector:
##  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20
##  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3
## 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40
##  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3
## 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60
##  3  3  3  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160
##  2  2  2  2  2  2  2  2  2  2  1  1  1  1  1  1  1  1  1  1
## 161 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179 180
##  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
## 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197 198 199 200
##  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
## 201 202 203 204 205
##  1  1  1  1  1
##
## Within cluster sum of squares by cluster:
```

```
## [1] 16820233 13293543 6032057
## (between_SS / total_SS = 85.9 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss"
## [6] "betweenss"    "size"         "iter"         "ifault"       "
```

```
1 grups_km$cluster # grup al qual pertanyen les dades
```

```
##  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20
##  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3
## 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40
##  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3  3
## 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60
##  3  3  3  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140
##  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2  2
## 141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160
##  2  2  2  2  2  2  2  2  2  2  2  1  1  1  1  1  1  1  1  1
## 161 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179 180
##  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
## 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197 198 199 200
##  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
## 201 202 203 204 205
##  1  1  1  1  1
```

```
1 plot(grups_km$cluster)
```



Exercici 10. ANOVA

A partir del conjunt de dades Iris, apliqueu la funció ANOVA i raoneu els resultats obtinguts.

Resposta:

```
1 # Carreguem el conjunt de dades iris
2 data(iris)
3 # Fem una anàlisi de variància (ANOVA) per comparar les longituds de pètals
4 # entre espècies
5 model_anova <- aov(Petal.Length ~ Species, data = iris)
6 # Resum de l'ANOVA
7 summary(model_anova)
```

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Species      2  437.1   218.55   1180 <2e-16 ***
## Residuals    147    27.2     0.19
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Com podem veure, hi ha una diferència significativa en les longituds dels pètals entre almenys un parell d'espècies d'Iris («setosa», «versicolor», i «virginica»). El valor p és molt petit i indica que les diferències observades no són aleatòries i són estadísticament significatives.

Cas pràctic 1. Models supervisats. Regressió lineal i múltiple

A partir del conjunt de dades Ovarian del paquet survival, feu un estudi de regressió lineal sobre un parell de variables que, a priori, penseu que poden presentar correlació, i un estudi de regressió múltiple seleccionant els millors predictors.

Resposta:

```
1 # Carreguem el paquet survival i el conjunt de dades ovarian
2 library(survival)
3 data(ovarian)
4 # Accedint a Packages / Survival / Ovarian, podem visualitzar la descripció
5 # d'aquest conjunt de dades referents a dades de supervivència de càncer
6 # d'ovari
7 # Visualitzem alguns registres del conjunt de dades d'Ovarian
8 head(ovarian)
```

```
##      futime fustat      age resid.ds rx ecog.ps
## 1      59      1 72.3315          2  1      1
## 2     115      1 74.4932          2  1      1
## 3     156      1 66.4658          2  1      2
## 4     421      0 53.3644          2  2      1
## 5     431      1 50.3397          2  1      1
## 6     448      0 56.4301          1  1      2
```

```
1 # Revisem el tipus de variables d'Ovarian i comprovem que totes elles són numèriques
2 str(ovarian)
```

```
## 'data.frame':   26 obs. of  6 variables:
##  $ futime   : num  59 115 156 421 431 448 464 475 477 563 ...
##  $ fustat   : num  1 1 1 0 1 0 1 1 0 1 ...
##  $ age      : num  72.3 74.5 66.5 53.4 50.3 ...
##  $ resid.ds: num  2 2 2 2 2 1 2 2 2 1 ...
##  $ rx       : num  1 1 1 2 1 1 2 2 1 2 ...
##  $ ecog.ps  : num  1 1 2 1 1 2 2 2 1 2 ...
```

```

1 # Mostrem un resum estadístic d'Ovarian
2 summary(ovarian)

```

```

##          futime          fustat          age          resid.ds
## Min.   : 59.0    Min.   :0.0000   Min.   :38.89   Min.   :1.000
## 1st Qu.: 368.0    1st Qu.:0.0000   1st Qu.:50.17   1st Qu.:1.000
## Median : 476.0    Median :0.0000   Median :56.85   Median :2.000
## Mean   : 599.5    Mean   :0.4615   Mean   :56.17   Mean   :1.577
## 3rd Qu.: 794.8    3rd Qu.:1.0000   3rd Qu.:62.38   3rd Qu.:2.000
## Max.   :1227.0    Max.   :1.0000   Max.   :74.50   Max.   :2.000
##          rx          ecog.ps
## Min.   :1.0    Min.   :1.000
## 1st Qu.:1.0    1st Qu.:1.000
## Median :1.5    Median :1.000
## Mean   :1.5    Mean   :1.462
## 3rd Qu.:2.0    3rd Qu.:2.000
## Max.   :2.0    Max.   :2.000


```

Fem els diagrames de punts de la relació entre variables:

```

1 pairs(~ ovarian$futime + ovarian$fustat + ovarian$age + ovarian$resid.ds + ovarian$rx + ovarian$ecog.ps)

```



Aquest gràfic pot aportar una idea sobre quines variables podrien tenir alguna relació; sembla intuir-se que `age` amb `futime`. A continuació, calculem el coeficient de correlació d'aquestes dues variables:

```

1 # Coeficient de correlació age vs futime que fa referència a l'edat i el temps
2 # de supervivència
3 cor(ovarian[, c("age", "futime")], use = "complete")

```

```

##          age          futime
## age      1.0000000 -0.6483612
## futime -0.6483612  1.0000000

```

Veiem que el grau de correlació és de -0.648, que és un valor bastant acceptable per indicar que existeix alguna correlació entre totes dues variables. Generem el model lineal corresponent a l'estimació per mínims quadrats:


```
1 RegModel.2 <- lm(futime ~ age, data = ovarian)
2 summary(RegModel.2)

##
## Call:
## lm(formula = futime ~ age, data = ovarian)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -554.63 -160.13  -49.27   67.21  702.11
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1824.240    298.079   6.120 2.54e-06 ***
## age         -21.805     5.227  -4.172 0.000341 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 263.9 on 24 degrees of freedom
## Multiple R-squared:  0.4204, Adjusted R-squared:  0.3962
## F-statistic: 17.41 on 1 and 24 DF,  p-value: 0.0003408
1 lm(formula = futime ~ age, data = ovarian)
```

```
##
## Call:
## lm(formula = futime ~ age, data = ovarian)
##
## Coefficients:
## (Intercept)      age
##    1824.24    -21.81
```

El valor de R-squared ens dona informació sobre el grau d'ajust del model. Aquest serà major com més pròxim a 1. En el nostre cas, aquest ajust és del 0.4204. D'altra banda, el p-value és inferior a 0.05, fet que sembla indicar que poguéss haver-hi una relació entre les dues variables. Dibuixem la recta de mínims quadrats:

```
1 plot(ovarian$age, ovarian$futime, xlab = "age", ylab = "futime")
2 abline(RegModel.2)
```



L'anterior representació ens continua reforçant la idea que existeix una correlació entre la variable `age` i `futime`. Fem ara un model de regressió múltiple per comprovar si la supervivència del càncer d'ovari ve determinada per algun factor més. Per fer-ho, inicialment calculem el coeficient de correlació de Pearson per a les diferents combinacions:

```
1 cor(x = ovarian, method = "pearson")
```

```
##          futime    fustat      age   resid.ds      rx    ecog.ps
## futime    1.0000000 -0.6898795 -0.64836121 -0.38518677  0.24687108  0.01425371
## fustat   -0.68987946  1.0000000  0.49586611  0.32433749 -0.15430335  0.22619048
## age      -0.64836121  0.4958661  1.00000000  0.29339868  0.04372768  0.12927600
## resid.ds -0.38518677  0.3243375  0.29339868  1.00000000 -0.07784989 -0.14414999
## rx        0.24687108 -0.1543033  0.04372768 -0.07784989  1.00000000  0.00000000
## ecog.ps   0.01425371  0.2261905  0.12927600 -0.14414999  0.00000000  1.00000000
```

De les dades anteriors sembla derivar-se que la variable `fustat` també presenta alguna relació amb la variable `futime`.

```
1 mrm_ovarian <- lm(ovarian$futime ~ ovarian$fustat + ovarian$age + ovarian$resid.ds + ovarian$rx + ovarian$ecog.ps, data = ovarian)
2 summary(mrm_ovarian)
```

```
##
## Call:
## lm(formula = ovarian$futime ~ ovarian$fustat + ovarian$age +
##     ovarian$resid.ds + ovarian$rx + ovarian$ecog.ps, data = ovarian)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -374.48 -103.23  -12.18   77.76  384.41
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1276.931     327.157   3.903 0.000882 ***
## ovarian$fustat   -309.207     105.682  -2.926 0.008357 **
```

```
## ovarian$age      -14.373      5.083  -2.828 0.010401 *
## ovarian$resid.ds -48.136     95.331  -0.505 0.619126
## ovarian$rx       125.638     87.254   1.440 0.165364
## ovarian$ecog.ps  109.503     90.484   1.210 0.240315
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 217.3 on 20 degrees of freedom
## Multiple R-squared:  0.6727, Adjusted R-squared:  0.5909
## F-statistic: 8.223 on 5 and 20 DF,  p-value: 0.0002355
```

El model anterior generat, una vegada que hem suposat totes les variables com a predictors, resulta un coeficient de determinació Multiple R-squared bastant acceptable (0.6727), i el p-value també és significatiu. Ara, d'entre tots els predictors possibles, hauríem de seleccionar els millors. Fem el següent:

```
1 step(mrm_ovarian, direction = "both")

## Start:  AIC=285
## ovarian$futime ~ ovarian$fustat + ovarian$age + ovarian$resid.ds +
##      ovarian$rx + ovarian$ecog.ps
##
##              Df Sum of Sq    RSS    AIC
## - ovarian$resid.ds  1      12034  956070 283.32
## - ovarian$ecog.ps   1       69130 1013166 284.83
## <none>                                944036 285.00
## - ovarian$rx        1       97865 1041901 285.56
## - ovarian$age       1      377400 1321436 291.74
## - ovarian$fustat    1      404069 1348105 292.26
##
## Step:  AIC=283.32
## ovarian$futime ~ ovarian$fustat + ovarian$age + ovarian$rx +
##      ovarian$ecog.ps
##
##              Df Sum of Sq    RSS    AIC
## <none>                                956070 283.32
## - ovarian$ecog.ps   1       88920 1044991 283.64
## - ovarian$rx        1      101328 1057398 283.94
## + ovarian$resid.ds  1       12034  944036 285.00
## - ovarian$age       1      414281 1370351 290.69
## - ovarian$fustat    1      467936 1424007 291.68
##
## Call:
## lm(formula = ovarian$futime ~ ovarian$fustat + ovarian$age +
##      ovarian$rx + ovarian$ecog.ps, data = ovarian)
##
## Coefficients:
## (Intercept)  ovarian$fustat  ovarian$age  ovarian$rx
##      1213.26      -322.41      -14.82      127.70
## ovarian$ecog.ps
##      120.52
```

Les variables potencials de ser predictors són les especificades en l'anterior Call. Executem de nou el model:

```
1 mrm_ovarian_predictors <- (lm(formula = ovarian$futime ~ ovarian$fustat + ovarian$age + ovarian$rx + ov
2 summary(mrm_ovarian_predictors)
```

```
##
## Call:
## lm(formula = ovarian$futime ~ ovarian$fustat + ovarian$age +
##     ovarian$rx + ovarian$ecog.ps, data = ovarian)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -377.09  -94.77  -16.40   73.50  400.66
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1213.263     296.477   4.092 0.000521 ***
## ovarian$fustat   -322.407     100.565  -3.206 0.004244 **
## ovarian$age      -14.824       4.914  -3.017 0.006568 **
## ovarian$rx        127.701      85.599   1.492 0.150606
## ovarian$ecog.ps   120.524      86.240   1.398 0.176842
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 213.4 on 21 degrees of freedom
## Multiple R-squared:  0.6686, Adjusted R-squared:  0.6054
## F-statistic: 10.59 on 4 and 21 DF,  p-value: 7.383e-05
```

En teoria, i amb les dades de què disposem, aquest seria el model que explicaria quins factors influeixen en la supervivència del càncer d'ovari.

Cas pràctic 2. Models d'aprenentatge automàtic i ANOVA

A partir del conjunt de dades `lung` del paquet `survival`, es demana fer un breu estudi aplicant els conceptes estudiats en aquest **LAB**. Per fer-ho, es demana dur a terme un estudi de regressió lineal, regressió múltiple, test ANOVA i test clustering sobre aquest conjunt de dades. Les variables triades en cadascun dels casos possibles a tractar es donen a triar a l'estudiant.

Resposta:

Carreguem el conjunt de dades:

```
1 # Carreguem el paquet survival i el conjunt de dades lung
2 library(survival)
3 data("lung")
4 # Visualitzem els primers registres
5 head(lung)
```

```
##   inst time status age sex ph.ecog ph.karno pat.karno meal.cal wt.loss
## 1    3  306      2  74  1        1        90        100    1175      NA
## 2    3  455      2  68  1        0        90         90    1225      15
## 3    3 1010      1  56  1        0        90         90      NA      15
## 4    5  210      2  57  1        1        90         60    1150      11
## 5    1  883      2  60  1        0       100         90      NA       0
## 6   12 1022      1  74  1        1        50         80    513       0
```

Revisem l'estructura de dades:

```
1 # Analitzem el tipus de variables i observem que totes són numèriques
2 str(lung)
```

```
## 'data.frame':   228 obs. of  10 variables:
## $ inst      : num  3 3 3 5 1 12 7 11 1 7 ...
```



```
## $ time      : num  306 455 1010 210 883 ...
## $ status    : num   2 2 1 2 2 1 2 2 2 ...
## $ age       : num   74 68 56 57 60 74 68 71 53 61 ...
## $ sex       : num   1 1 1 1 1 1 2 2 1 1 ...
## $ ph.ecog   : num   1 0 0 1 0 1 2 2 1 2 ...
## $ ph.karno  : num   90 90 90 90 100 50 70 60 70 70 ...
## $ pat.karno : num  100 90 90 60 90 80 60 80 80 70 ...
## $ meal.cal  : num  1175 1225 NA 1150 NA ...
## $ wt.loss   : num   NA 15 15 11 0 0 10 1 16 34 ...
```

```
1 # Eliminem els valors NA
2 data_lung <- na.omit(lung)
3 # Fem un breu resum estadístic
4 summary(lung)
```

```
##      inst      time      status      age
## Min.   : 1.00   Min.   : 5.0   Min.   :1.000   Min.   :39.00
## 1st Qu.: 3.00   1st Qu.: 166.8   1st Qu.:1.000   1st Qu.:56.00
## Median :11.00   Median : 255.5   Median :2.000   Median :63.00
## Mean   :11.09   Mean   : 305.2   Mean   :1.724   Mean   :62.45
## 3rd Qu.:16.00   3rd Qu.: 396.5   3rd Qu.:2.000   3rd Qu.:69.00
## Max.   :33.00   Max.   :1022.0   Max.   :2.000   Max.   :82.00
## NA's    :1
##      sex      ph.ecog      ph.karno      pat.karno
## Min.   :1.000   Min.   :0.0000   Min.   : 50.00   Min.   : 30.00
## 1st Qu.:1.000   1st Qu.:0.0000   1st Qu.: 75.00   1st Qu.: 70.00
## Median :1.000   Median :1.0000   Median : 80.00   Median : 80.00
## Mean   :1.395   Mean   :0.9515   Mean   : 81.94   Mean   : 79.96
## 3rd Qu.:2.000   3rd Qu.:1.0000   3rd Qu.: 90.00   3rd Qu.: 90.00
## Max.   :2.000   Max.   :3.0000   Max.   :100.00   Max.   :100.00
##      meal.cal      wt.loss
## Min.   : 96.0   Min.   : -24.000
## 1st Qu.: 635.0   1st Qu.:  0.000
## Median : 975.0   Median :  7.000
## Mean   : 928.8   Mean   :  9.832
## 3rd Qu.:1150.0   3rd Qu.: 15.750
## Max.   :2600.0   Max.   : 68.000
## NA's    :47     NA's    :14
```


Una vegada que tinguem una primera vista del conjunt de dades lung, procedirem a valorar si hi ha alguna correlació clara entre les variables d'aquest conjunt de dades.

```
1 # Calculem la matriu de correlació
2 cor(x = data_lung, method = "pearson")
```

```
##      inst      time      status      age      sex
## inst      1.00000000  0.02462876 -0.12719801  0.04859452  0.084362910
## time      0.02462876  1.00000000 -0.16217237 -0.07854153  0.114149616
## status    -0.12719801 -0.16217237  1.00000000  0.15911933 -0.218780030
## age       0.04859452 -0.07854153  0.15911933  1.00000000 -0.125280356
## sex       0.08436291  0.11414962 -0.21878003 -0.12528036  1.000000000
## ph.ecog   0.05947203 -0.19116847  0.23805821  0.30865378 -0.005363288
## ph.karno  -0.02252266  0.09487913 -0.16127595 -0.32261297 -0.019623924
## pat.karno  0.04147893  0.17505701 -0.18542442 -0.23989736  0.071014942
## meal.cal  0.09869124  0.07467151  0.02483564 -0.23958240 -0.171044801
```

```
## wt.loss    -0.17485406  0.03342528  0.04868879  0.04286056 -0.169892775
##           ph.ecog    ph.karno    pat.karno    meal.cal    wt.loss
## inst       0.059472025 -0.02252266  0.04147893  0.09869124 -0.17485406
## time      -0.191168469  0.09487913  0.17505701  0.07467151  0.03342528
## status     0.238058213 -0.16127595 -0.18542442  0.02483564  0.04868879
## age        0.308653782 -0.32261297 -0.23989736 -0.23958240  0.04286056
## sex        -0.005363288 -0.01962392  0.07101494 -0.17104480 -0.16989278
## ph.ecog     1.000000000 -0.82269739 -0.54719617 -0.10563039  0.17125740
## ph.karno    -0.822697393  1.00000000  0.53502749  0.05385409 -0.12524032
## pat.karno   -0.547196168  0.53502749  1.00000000  0.17465190 -0.18213953
## meal.cal    -0.105630385  0.05385409  0.17465190  1.00000000 -0.11134425
## wt.loss     0.171257402 -0.12524032 -0.18213953 -0.11134425  1.00000000
```

```
1 # Representem la relació entre les variables
2 pairs(data_lung)
```




Revisant els coeficients de Pearson de cada parell de variables, potser dues variables sobre les quals podem calcular el model de regressió lineal són `ph.ecog` i `ph.karno`.

```
1 # Fem el model de regressió lineal
2 lung_rl <- lm(formula = ph.ecog ~ ph.karno, data = data_lung)
3 # Mostres el resultat
4 summary(lung_rl)
```

```
##
## Call:
## lm(formula = ph.ecog ~ ph.karno, data = data_lung)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.4658 -0.1127 -0.0539  0.4167  1.0049
##
```

```
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.818865   0.210176   22.93  <2e-16 ***
## ph.karno    -0.047062   0.002532  -18.59  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4168 on 165 degrees of freedom
## Multiple R-squared:  0.6768, Adjusted R-squared:  0.6749
## F-statistic: 345.6 on 1 and 165 DF,  p-value: < 2.2e-16
```

```
1 # Representem el diagrama de punts
2 plot(data_lung$ph.karno, data_lung$ph.ecog, xlab = "ph.karno", ylab = "ph.ecog")
3 abline(lung_rl)
```



El model de regressió mostra un R-squared de 0.6768, fet que indica un bon ajust d'aquest model. A continuació, farem el model de regressió múltiple avaluant quins són els possibles predictors per a la variable ph.ecog. Per fer-ho, executem les instruccions següents:

```
1 # Model de regressió múltiple
2 lung_rm <- lm(
3   data_lung$ph.ecog ~ data_lung$inst + data_lung$time
4   + data_lung$status + data_lung$age + data_lung$ph.karno
5   + data_lung$pat.karno + data_lung$meal.cal + data_lung$wt.loss,
6   data = data_lung
7 )
8 summary(lung_rm)
```

```
##
## Call:
## lm(formula = data_lung$ph.ecog ~ data_lung$inst + data_lung$time +
##     data_lung$status + data_lung$age + data_lung$ph.karno + data_lung$pat.karno +
##     data_lung$meal.cal + data_lung$wt.loss, data = data_lung)
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.07182 -0.20748  0.00247  0.29444  0.92569
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    4.523e+00  4.099e-01  11.033  <2e-16 ***
## data_lung$inst    6.881e-03  3.901e-03   1.764  0.0797 .
## data_lung$time   -3.099e-04  1.516e-04  -2.044  0.0426 *
## data_lung$status  1.499e-01  7.177e-02   2.089  0.0383 *
## data_lung$age     8.339e-04  3.686e-03   0.226  0.8213
## data_lung$ph.karno -4.154e-02  2.963e-03 -14.020  <2e-16 ***
## data_lung$pat.karno -5.185e-03  2.514e-03  -2.063  0.0408 *
## data_lung$meal.cal -7.251e-05  7.894e-05  -0.919  0.3598
## data_lung$wt.loss  3.698e-03  2.394e-03   1.545  0.1244
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3973 on 158 degrees of freedom
## Multiple R-squared:  0.7188, Adjusted R-squared:  0.7046
## F-statistic: 50.49 on 8 and 158 DF,  p-value: < 2.2e-16
```

Una vegada calculats tots els coeficients dels possibles predictors, avaluem quins són els millors predictors:

```
1 # Analitzem els millors predictors
2 step(object = lung_rm, direction = "both", trace = 1)

## Start:  AIC=-299.54
## data_lung$ph.ecog ~ data_lung$inst + data_lung$time + data_lung$status +
##      data_lung$age + data_lung$ph.karno + data_lung$pat.karno +
##      data_lung$meal.cal + data_lung$wt.loss
##
##              Df Sum of Sq  RSS    AIC
## - data_lung$age      1    0.0081 24.951 -301.48
## - data_lung$meal.cal  1    0.1332 25.076 -300.65
## <none>                  24.942 -299.54
## - data_lung$wt.loss   1    0.3767 25.319 -299.03
## - data_lung$inst      1    0.4911 25.434 -298.28
## - data_lung$time      1    0.6597 25.602 -297.18
## - data_lung$pat.karno  1    0.6716 25.614 -297.10
## - data_lung$status    1    0.6888 25.631 -296.99
## - data_lung$ph.karno  1   31.0307 55.973 -166.55
##
## Step:  AIC=-301.48
## data_lung$ph.ecog ~ data_lung$inst + data_lung$time + data_lung$status +
##      data_lung$ph.karno + data_lung$pat.karno + data_lung$meal.cal +
##      data_lung$wt.loss
##
##              Df Sum of Sq  RSS    AIC
## - data_lung$meal.cal  1    0.158 25.109 -302.43
## <none>                  24.951 -301.48
## - data_lung$wt.loss   1    0.375 25.326 -300.99
## - data_lung$inst      1    0.506 25.456 -300.13
## + data_lung$age       1    0.008 24.942 -299.54
## - data_lung$time      1    0.661 25.612 -299.11
```

```
## - data_lung$pat.karno 1      0.677 25.628 -299.01
## - data_lung$status 1      0.720 25.671 -298.73
## - data_lung$ph.karno 1     33.216 58.166 -162.13
##
## Step: AIC=-302.43
## data_lung$ph.ecog ~ data_lung$inst + data_lung$time + data_lung$status +
##      data_lung$ph.karno + data_lung$pat.karno + data_lung$wt.loss
##
##              Df Sum of Sq    RSS    AIC
## <none>                25.109 -302.43
## - data_lung$wt.loss 1      0.414 25.523 -301.70
## + data_lung$meal.cal 1      0.158 24.951 -301.48
## - data_lung$inst 1      0.462 25.571 -301.38
## + data_lung$age 1      0.033 25.076 -300.65
## - data_lung$status 1      0.674 25.783 -300.00
## - data_lung$time 1      0.703 25.812 -299.82
## - data_lung$pat.karno 1      0.802 25.911 -299.17
## - data_lung$ph.karno 1     33.085 58.194 -164.05
##
## Call:
## lm(formula = data_lung$ph.ecog ~ data_lung$inst + data_lung$time +
##      data_lung$status + data_lung$ph.karno + data_lung$pat.karno +
##      data_lung$wt.loss, data = data_lung)
##
## Coefficients:
##      (Intercept)      data_lung$inst      data_lung$time
##      4.5535875      0.0066252      -0.0003192
##      data_lung$status data_lung$ph.karno data_lung$pat.karno
##      0.1466834      -0.0415905      -0.0055947
##      data_lung$wt.loss
##      0.0038653
```

En el resultat del call anterior s'aprecien quins serien els millors predictors. Calculem de nou el model de regressió sobre aquests predictors:

```
1 # Model de regressió amb els millors predictors
2 lung_rm_p <- lm(
3     formula = data_lung$ph.ecog ~ data_lung$inst + data_lung$time
4         + data_lung$status + data_lung$ph.karno + data_lung$pat.karno
5         + data_lung$wt.loss,
6     data = data_lung
7 )
8 summary(lung_rm_p)
```

```
##
## Call:
## lm(formula = data_lung$ph.ecog ~ data_lung$inst + data_lung$time +
##      data_lung$status + data_lung$ph.karno + data_lung$pat.karno +
##      data_lung$wt.loss, data = data_lung)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.16209 -0.22765 -0.01216  0.30052  0.92432
##
## Coefficients:
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    4.5535875  0.2816769  16.166 <2e-16 ***
## data_lung$inst    0.0066252  0.0038613   1.716  0.0881 .
## data_lung$time   -0.0003192  0.0001509  -2.116  0.0359 *
## data_lung$status    0.1466834  0.0707557   2.073  0.0398 *
## data_lung$ph.karno -0.0415905  0.0028644 -14.520 <2e-16 ***
## data_lung$pat.karno -0.0055947  0.0024744  -2.261  0.0251 *
## data_lung$wt.loss    0.0038653  0.0023803   1.624  0.1064
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3961 on 160 degrees of freedom
## Multiple R-squared:  0.7169, Adjusted R-squared:  0.7063
## F-statistic: 67.54 on 6 and 160 DF,  p-value: < 2.2e-16
```

S'observa que l'ajust del model R-squared (0.7169) s'ha incrementat respecte a anteriors càlculs. Fem ara el test ANOVA per a les variables sex i time.

```
1 # definim els vectors de les variables sex i time
2 sex_lung <- c(data_lung$sex)
3 time_lung <- c(data_lung$time)
4 # definim el data frame que guardi aquests dos vectors
5 df_lung <- data.frame(time_lung, sex_lung)
6 # mostrem els primers registres
7 head(df_lung)
```

```
##   time_lung sex_lung
## 1      455        1
## 2      210        1
## 3     1022        1
## 4      310        2
## 5      361        2
## 6      218        1
```

```
1 # mostrem el nombre d'observacions per a cada grup (sexe)
2 table(df_lung$sex_lung)
```


```
##
##    1    2
## 103  64
```

S'observa que el nombre d'observacions és desigual en cada grup. Vegem la mitjana del temps de supervivència en funció del sexe.

```
1 # Calculem la mitjana del temps de supervivència en funció del ph.ecog
2 aggregate(time_lung ~ sex_lung, data = df_lung, FUN = mean)
```

```
##   sex_lung time_lung
## 1        1 291.1456
## 2        2 340.1719
```

```
1 # Calculem el diagrama de caixes
2 boxplot(time_lung ~ sex_lung, data = df_lung, id.method = "y")
```



Per determinar la normalitat apliquem el test de Kolmogorov-Smirnov, ja que disposem de més de 50 observacions.


```
1 require(nortest)
2 by(data = df_lung, INDICES = df_lung$sex_lung, FUN = function(x) {
3   lillie.test(x$time_lung)
4 })
```

```
## df_lung$sex_lung: 1
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  x$time_lung
## D = 0.16663, p-value = 1.904e-07
##
## -----
## df_lung$sex_lung: 2
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  x$time_lung
## D = 0.12018, p-value = 0.02246
```

Es pot observar que tots dos grups tenen un p-value inferior a 0.05, amb la qual cosa es determina que cap dels dos grups compleix les condicions de normalitat. Per tant, no té sentit fer el test d'ANOVA. Finalment, farem un test de clustering i, per fer-ho, comencem amb un agrupament jeràrquic aglomeratiu.

```
1 # Agrupament jeràrquic aglomeratiu. Cada observació és un clúster que es va
2 # organitzant fins a convergir en una única branca central.
3 library(MASS)
4 library(cluster)
5 d_agl_lung <- dist(data_lung, method = "euclidean") # especifiquem els valors de distància
6 hc_agl_lung <- hclust(d_agl_lung, method = "complete") # calculem el clúster jeràrquic
7 plot(hc_agl_lung, cex = 0.6, hang = -1, main = "Dendrograma de cluster")
```

Dendrograma de cluster




d_agl_lung
hclust (*, "complete")

Ara fem un agrupament jeràrquic aplicant la funció `agnes()`:

```
1 hc_ag_lung <- agnes(data_lung, method = "complete") # calculem els clústers jeràrquics
2 pltree(hc_ag_lung, cex = 0.6, hang = -1, main = "Dendrograma d'agnes")
```


Dendrograma d'agnes



data_lung
agnes (*, "complete")


```
1 # representem el dendrograma
2 hc_ag_lung$ac # calculem el coeficient d'aglomeració
```

```
## [1] 0.9723202
```

El coeficient és pròxim a 1, o sigui que l'agrupació és forta. Ara repetim el procés utilitzant la funció diana.

```
1 # Agrupament divisional jeràrquic
2 hc_div_lung <- diana(data_lung) # calculem els clústers jeràrquics
3 pltree(hc_div_lung, cex = 0.6, hang = -1, main = "Dendrograma de Diana")
```

Dendrograma de Diana



data_lung
diana (*, "NA")


```
1 # representem el dendrograma
2 hc_div_lung$dc # calculem el coeficient de divisió
```

```
## [1] 0.9705904
```

El coeficient també és molt pròxim a 1. Per associar els agrupaments a les dades, fem:

```
1 pltree(hc_div_lung, hang = -1, cex = 0.6)
2 rect.hclust(hc_div_lung, k = 10, border = 2:10)
```

Dendrogram of `diana(x = data_lung)`



`data_lung`
`diana (*, "NA")`

Cas pràctic 3. ANOVA

A partir del conjunt de dades `birthwt` del paquet `MASS`, intentarem obtenir conclusions sobre la relació existent entre la raça de la mare, tenint en compte si aquesta és o no fumadora, i el baix pes del nounat. Aquest estudi podria contextualitzar-se en una prova ANOVA d'una via per a dades independents.

Resposta:

Definim el conjunt de dades de l'estudi a fer i n'extraïem informació:

```
1  # Definició de les dades d'estudi de birthwt
2  library(MASS)
3  data_birth <- MASS::birthwt
4  data_birth$race <-
5    factor(
6      data_birth$race,
7      levels = c(1, 2, 3),
8      labels = c("white", "black", "other")
9    )
10 # 1->white, 2->black, 3->other
11 head(data_birth)
```

```
##      low age lwt  race smoke ptl ht ui ftv  bwt
## 85    0  19 182 black     0   0  0  1   0 2523
## 86    0  33 155 other     0   0  0  0   3 2551
## 87    0  20 105 white     1   0  0  0   1 2557
## 88    0  21 108 white     1   0  0  1   2 2594
## 89    0  18 107 white     1   0  0  1   0 2600
## 91    0  21 124 other     0   0  0  0   0 2622
```

```

1  raca <- c(data_birth$race)
2  pes <- c(data_birth$bwt)
3  df_birth_anova <- data.frame(raca, pes) # definim el conjunt de dades
4  head(df_birth_anova, 4) # mostrem la informació del data frame

```

```

##    raca  pes
## 1 black 2523
## 2 other 2551
## 3 white 2557
## 4 white 2594

```

```

1  table(df_birth_anova$raca) # nombre d'observacions per a cada grup

```

```

##
## white black other
##    96    26    67

```

El nombre d'observacions no és constant per a cada grup i, en algun d'ells, les diferències són significatives.

Calculem ara la mitjana i desviació típica per a cada grup.

```

1  # Mitjana de pesos per raça
2  aggregate(pes ~ raca, data = df_birth_anova, FUN = mean)

```

```

##    raca      pes
## 1 white 3102.719
## 2 black 2719.692
## 3 other 2805.284

```

```

1  # Desviació típica de pesos per raça
2  aggregate(pes ~ raca, data = df_birth_anova, FUN = sd)

```

```

##    raca      pes
## 1 white 727.8861
## 2 black 638.6839
## 3 other 722.1944


```

Vegem en una representació gràfica si poguessin haver-hi asimetries, dades atípiques o altres diferències significatives:

```

1  boxplot(data_birth$bwt ~ data_birth$race, data = data_birth, id.method = "y")

```



Encara que s'observen valors atípics i petites diferències entre la grandària de les caixes, els tres grups semblen seguir una distribució bastant simètrica. Seguim endavant amb l'estudi i ara comprovem les condicions per aplicar un ANOVA. Disposem d'una mostra d'estudi on les observacions de cada grup són independents entre si.

A continuació, farem un test que acabarà de determinar la normalitat de la distribució. Normalment, s'aplica el test de Shapiro-Wilk si la mostra és inferior a 50 observacions, o el test de Kolmogorov-Smirnov, si aquesta mostra és superior. En el nostre cas aplicarem aquest últim test.

```
1 # Test Kolmogorov-Smirnov
2 require(nortest)
3 # Loading required package: nortest
4 by(data = df_birth_anova, INDICES = df_birth_anova$racas, FUN = function(x) {
5     lillie.test(x$pes)
6 })
```

```
## df_birth_anova$racas: white
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  x$pes
## D = 0.090389, p-value = 0.05113
##
## -----
## df_birth_anova$racas: black
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  x$pes
## D = 0.1231, p-value = 0.3946
##
## -----
## df_birth_anova$racas: other
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: x$pes
## D = 0.11598, p-value = 0.02578
```

Els anteriors tests de normalitat mostren falta de normalitat en algun grup, per exemple, el grup 3. Això ve determinat pel valor del p-value. En general, s'accepta la hipòtesi de normalitat si aquest valor és superior a 0.05. Podem comprovar, també, que el grup 1 estaria al límit d'acceptar aquesta normalitat. A continuació, hem d'avaluar la variància constant entre els grups, denominada homoscedasticitat. Per fer-ho, hi ha diferents tests que podem aplicar en funció dels resultats de normalitat; si aquests no són clarament acceptables, desestimem utilitzar el test de Fisher i el test de Bartlett i apliquem el test de Levene (aconsellable si tenim variables categòriques) o el test de Fligner-Killeen.

```
1 # Test Fligner-Killeen diagnosi homoscedasticitat
2 fligner.test(df_birth_anova$pes ~ df_birth_anova$raca, df_birth_anova)
```



```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: df_birth_anova$pes by df_birth_anova$raca
## Fligner-Killeen:med chi-squared = 1.0086, df = 2, p-value = 0.6039
```



No es detecta falta d'homoscedasticitat. A priori, si no es compleixen les condicions d'ANOVA, no seria necessari continuar amb l'estudi. No obstant això, excepte casos concrets, convé continuar avançant, ja que posteriors estudis ens poden aportar més informació.

```
1 ## Estudi anova
2 anova_birthwt <- aov(
3   df_birth_anova$pes ~ df_birth_anova$raca,
4   data = df_birth_anova
5 )
6 summary(anova_birthwt)
```

```
##              Df    Sum Sq Mean Sq F value    Pr(>F)
## df_birth_anova$raca    2  5015725 2507863    4.913 0.00834 **
## Residuals          186  94953931  510505
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
1 plot(anova_birthwt)
```





Dels resultats anteriors es desprèn que sí que pot haver-hi diferències estadísticament significatives entre les races de les mares. En els casos en els quals es detecten diferències significatives entre les mitjanes dels grups, s'utilitzarien mètodes de comparacions múltiples i correccions.

Les més recomanades són Correcció de Holm i TukeyHSD.


```

1 pairwise.t.test(
2     x = df_birth_anova$pes,
3     g = df_birth_anova$raca,
4     p.adjust.method = "holm",
5     pool.sd = TRUE,
6     paired = FALSE,
7     alternative = "two.sided"
8 )

##
## Pairwise comparisons using t tests with pooled SD
##
## data: df_birth_anova$pes and df_birth_anova$raca
##
##      white black
## black 0.033 -
## other 0.029 0.605
##
## P value adjustment method: holm

```